BITÁCORA 3 - GRUPO 2

Integrantes

-Cristhian Jimenez Campos C33973

-Olman Camacho Jerez C31523

-Jose Manuel Alfaro Monge C30244

Bitácora 1

Pregunta de investigación

¿Cuáles son los factores individuales, sociales y académicos que más inciden en la predicción de la deserción escolar en estudiantes de nivel secundario?

Objeto de estudio

El objeto de estudio es el fenómeno de la deserción escolar, entendido como el abandono prematuro del sistema educativo formal por parte de los estudiantes antes de completar el nivel educativo correspondiente.

Conceptos

Deserción escolar:

Según Spady, citado por Floricely Dzay Chulim (2012), se mencionan dos definiciones operacionales acerca de la deserción universitaria:

a) Incluye a cualquier persona que abandona la institución de educación superior donde se encuentra registrada.

b) Se refiere a aquellas personas que no reciben un título o grado de ninguna universidad.

Esta segunda definición sostiene que el o la estudiante que haya iniciado un proceso de aprendizaje superior y, en un determinado periodo de tiempo, no haya obtenido su respectivo título o grado, puede considerarse un desertor.

Factores personales:

Se entienden como factores personales todas aquellas características internas del estudiante, como la motivación, las actitudes y las habilidades cognitivas, que influyen directamente en su aprendizaje.

Factores sociales:

Los factores sociales se refieren a todas aquellas influencias externas relacionadas con el entorno del estudiante, que se presentan en su vida de manera inesperada o no planificada, y que provienen directamente de su círculo personal (familiares, amigos cercanos, entre otros). Estas influencias pueden afectar directamente su rendimiento académico.

Teorías

Teoría de la frustración:

Esta teoría es un aporte del investigador Abram Amsel. Según Alejandro Baquero (2007), la Teoría de la Frustración de Amsel expone una hipótesis acerca de la función de la omisión decepcionante de una recompensa en circunstancias de refuerzo no continuo.

De acuerdo con esta teoría, en la etapa de adquisición, el sujeto aprende a prever la recompensa obtenida en el contexto experimental debido a la presencia de claves contextuales que la anuncian. Luego, cuando la recompensa se omite inesperadamente, el sujeto experimenta una reacción emocional natural y aversiva denominada **frustración**, la cual llega a asociarse con las señales que previamente indicaban una recompensa.

Esto genera un conflicto al inicio del entrenamiento, ya que tanto la frustración como la recompensa son pronosticadas por condicionamiento clásico ante los mismos estímulos. A medida que avanza el entrenamiento, por efecto del contracondicionamiento, el conflicto se resuelve a favor de la respuesta, ya que el refuerzo no es predecible en una situación de refuerzo incompleto. De esta forma, la respuesta continúa incluso durante la extinción, puesto que se ha condicionado la expectativa de ausencia de recompensa. En cambio, los sujetos que reciben refuerzo constante no desarrollan este tipo de respuesta al no experimentar la frustración asociada a la omisión del refuerzo.

Teoría de los factores múltiples

La teoría de los factores múltiples sostiene que la deserción escolar responde a una combinación de factores individuales, sociales y académicos.

Basándonos en la base de datos con la que se trabajará, algunos de estos factores son el desempeño académico, el nivel educativo y los factores familiares, los cuales pueden aumentar el riesgo de que un alumno abandone la institución educativa.

La deserción no se ve afectada por un único factor; generalmente se debe a la interacción de múltiples elementos y, en ocasiones, es difícil identificar todas las causas. Es fundamental detectar la deserción académica a tiempo para poder brindar apoyo mediante tutorías, asistencia económica y programas de acompañamiento psicológico, los cuales pueden ayudar a prevenir el abandono. Además, es importante identificar qué factores tienen mayor peso en la decisión de desertar.

Teoría de los factores económicos y apoyo familiar en la deserción universitaria

Esta teoría, sustentada en diversos estudios, señala que las dificultades económicas, tanto familiares como individuales, tienen un impacto significativo en los estudiantes, aumentando la probabilidad de abandono universitario.

Los problemas económicos generan una gran presión sobre los estudiantes, quienes en muchos casos deben colaborar con el sustento familiar, lo que puede llevarlos a dejar de lado sus estudios.

Para aliviar esta presión, el acceso a becas y ayudas financieras se identifica como un factor protector, ya que brinda apoyo económico y emocional, permitiendo que los estudiantes continúen su formación y mejoren su rendimiento académico.

Bibliografía

Miranda, J., & Vázquez, J. (2023). *Análisis de la deserción estudiantil universitaria desde una perspectiva analítica*. Revista N° 24, Facultad de Economía y Negocios. Recuperado de https://admisionfen.cl/wp-content/uploads/2024/03/Revista-N%C2%B024_jaime_miranda.pdf

Poveda Velasco, I. M. (2019). *Los factores que influyen sobre la deserción universitaria: Estudio en la UMRPSFXCh* [Investigación y Negocios, 12(20), 63–80]. Investigación y Negocios. https://www.scielo.org.bo/scielo.php?script=sci_arttext&pid=S2521-27372019000200007

[Autor(es)]. (2021). *Título del artículo*. Revista de Educación (o nombre completo), volumen (número), páginas. Recuperado de https://www.scielo.sa.cr/scielo.php?script=sci_arttext&pid=S2215-34702021000100019

[Autor(es)]. (2023). *Título del artículo*. Revista (o nombre de la revista), volumen (número), páginas. Recuperado de http://www.scielo.edu.uy/scielo.php?script=sci_arttext&pid=S1688-93042023000301206#B56

[Autor(es)]. (2014). *Título del artículo*. Revista (o nombre de la revista), volumen (número), páginas. Recuperado de http://www.scielo.org.co/scielo.php?script=sci_arttext&pid=S2145-94442014000200010

[Autor(es)]. (Año). *Título del artículo*. Revista Revie, volumen (número), páginas. Recuperado de https://revie.gob.do/index.php/revie/article/view/193/365

[Autor(es)]. (Año). *Título del artículo*. Revista RIDE, volumen (número), páginas. Recuperado de https://www.ride.org.mx/index.php/RIDE/article/view/1923/5020

Dzay Chulim, F., & Narváez Trejo, O. M. (2012). *La deserción escolar desde la perspectiva estudiantil*. La Editorial Manda. https://www.uv.mx/personal/onarvaez/files/2013/02/la-desercion-escolar.pdf

Bitácora 2

Datos

Características de la tabla:

Esta base de datos contiene registros de 4,424 estudiantes, quienes serán clasificados de distintas maneras, desde su estado civil hasta los cursos que están cursando, entre otros. La base de datos fue publicada en 2021 y presenta diversos factores, incluyendo variables relacionadas con los padres, para analizar si influyen en la vida académica del estudiante. Fue creada por Valentim Realinho, Mónica Vieira Martins, Jorge Machado y Luís Baptista, investigadores del Instituto Politécnico de Portalegre en Portugal, y puede ser descargada desde el enlace link. Los datos corresponden al segundo semestre, aunque no se especifica el año.

Las variables están organizadas en distintas categorías: variables relacionadas con la trayectoria académica, variables demográficas y variables socioeconómicas. Los tipos de datos incluyen variables continuas, categóricas y enteras.

Población de estudio:

Estudiantes matriculados en diferentes carreras de pregrado de una institución de educación superior.

Muestra observada:

4,424 estudiantes.

Unidad estadística o individuos:

Cada uno de los 4,424 estudiantes de educación superior durante determinados semestres.

Identificación de las variables de estudio:

Las variables de estudio incluyen información sobre la trayectoria académica, datos demográficos y factores socioeconómicos de los estudiantes, así como su rendimiento académico al final del primer y segundo semestre. El problema se plantea como una tarea de clasificación en tres categorías: abandono, matriculado y graduado.

Primeras 5 filas de la tabla de datos:

```r
library(dplyr)
library(ggplot2)
library(tidyr)
datos <- read.csv2("data.csv", sep = ";", header = TRUE, stringsAsFactors = FALSE)
datos <- datos %>%
  select(-GDP) ### El uso de esta variable es irrelevante
head(datos, 5)
```

```
  Marital.status Application.mode Application.order Course
1              1               17                 5    171
2              1               15                 1   9254
3              1                1                 5   9070
4              1               17                 2   9773
5              2               39                 1   8014
```

	Daytime.evening.attendance.	Previous.qualification
1	1	1
2	1	1
3	1	1
4	1	1
5	0	1

	Previous.qualification..grade.	Nacionality	Mother.s.qualification
1	122.0	1	19
2	160.0	1	1
3	122.0	1	37
4	122.0	1	38
5	100.0	1	37

	Father.s.qualification	Mother.s.occupation	Father.s.occupation
1	12	5	9
2	3	3	3
3	37	9	9
4	37	5	3
5	38	9	9

	Admission.grade	Displaced	Educational.special.needs	Debtor
1	127.3	1	0	0
2	142.5	1	0	0
3	124.8	1	0	0
4	119.6	1	0	0
5	141.5	0	0	0

	Tuition.fees.up.to.date	Gender	Scholarship.holder	Age.at.enrollment
1	1	1	0	20
2	0	1	0	19
3	0	1	0	19
4	1	0	0	20
5	1	0	0	45

	International	Curricular.units.1st.sem..credited.
1	0	0
2	0	0
3	0	0
4	0	0
5	0	0

	Curricular.units.1st.sem..enrolled.	Curricular.units.1st.sem..evaluations.
1	0	0
2	6	6
3	6	0
4	6	8
5	6	9

	Curricular.units.1st.sem..approved.	Curricular.units.1st.sem..grade.
1	0	0.0
2	6	14.0
3	0	0.0
4	6	13.428571428571429
5	5	12.333333333333334

	Curricular.units.1st.sem..without.evaluations.
1	0
2	0
3	0
4	0
5	0

	Curricular.units.2nd.sem..credited.	Curricular.units.2nd.sem..enrolled.
1	0	0
2	0	6
3	0	6
4	0	6
5	0	6

```
  Curricular.units.2nd.sem..evaluations. Curricular.units.2nd.sem..approved.
1                                      0                                     0
2                                      6                                     6
3                                      0                                     0
4                                     10                                     5
5                                      6                                     6
  Curricular.units.2nd.sem..grade.
1                              0.0
2                13.666666666666666
3                              0.0
4                             12.4
5                             13.0
  Curricular.units.2nd.sem..without.evaluations. Unemployment.rate
1                                              0              10.8
2                                              0              13.9
3                                              0              10.8
4                                              0               9.4
5                                              0              13.9
  Inflation.rate   Target
1            1.4  Dropout
2           -0.3 Graduate
3            1.4  Dropout
4           -0.8 Graduate
5           -0.3 Graduate
```

La tabla se encuentra en formato tabular, esto se puede ver y también se comenta en la página de descarga

Resumen de 5 números de las variables cuantitativas y analizar el mismo:

```
library(dplyr)
# Se seleciona las variables cuantitaticas
variables_cuantitativas <- select_if(datos, is.numeric)
# Calcular resumen de 5 números para cada variable
#'Vamos a usar sapply para aplicar la funcion fivenum a la base
#'el firenum es una funcion que nos ayuda a calcular el minimo y maximo, los Q1 y Q3, ad
resumen_5_numeros <- sapply(variables_cuantitativas, fivenum)
#para no tener problema trasponemos a resumen_5_numeros
resumen_5_numeros <- t(resumen_5_numeros)
#'Para facilitar la lectura vamos a ponerle nosmbres claros a las columnas
colnames(resumen_5_numeros) <- c("Minimo","Q1","Mediana","Q3","Máximo")
print(resumen_5_numeros)
```

	Minimo	Q1	Mediana	Q3	Máximo
Marital.status	1	1	1	1	6
Application.mode	1	1	17	39	57
Application.order	0	1	1	2	9
Course	33	9085	9238	9556	9991
Daytime.evening.attendance.	0	1	1	1	1
Previous.qualification	1	1	1	1	43
Nacionality	1	1	1	1	109
Mother.s.qualification	1	2	19	37	44
Father.s.qualification	1	3	19	37	44
Mother.s.occupation	0	4	5	9	194
Father.s.occupation	0	4	7	9	195
Displaced	0	0	1	1	1
Educational.special.needs	0	0	0	0	1

Debtor	0	0	0	0	1
Tuition.fees.up.to.date	0	1	1	1	1
Gender	0	0	0	1	1
Scholarship.holder	0	0	0	0	1
Age.at.enrollment	17	19	20	25	70
International	0	0	0	0	1
Curricular.units.1st.sem..credited.	0	0	0	0	20
Curricular.units.1st.sem..enrolled.	0	5	6	7	26
Curricular.units.1st.sem..evaluations.	0	6	8	10	45
Curricular.units.1st.sem..approved.	0	3	5	6	26
Curricular.units.1st.sem..without.evaluations.	0	0	0	0	12
Curricular.units.2nd.sem..credited.	0	0	0	0	19
Curricular.units.2nd.sem..enrolled.	0	5	6	7	23
Curricular.units.2nd.sem..evaluations.	0	6	8	10	33
Curricular.units.2nd.sem..approved.	0	2	5	6	20
Curricular.units.2nd.sem..without.evaluations.	0	0	0	0	12

La tabla muestra el resumen de cinco números de las variables cuantitativas de nuestra base de datos. En ella se puede observar que la mayoría de las variables tienen un valor mínimo de 0. La forma en que se evalúan nuestras variables es diferente, ya que cada una tiene rangos distintos para su asignación; por lo tanto, pueden ser continuas o presentar saltos en los valores, como pasar de 33 a 53, entre otros.

Hacer al menos un gráfico que describa la distribución para cada una de las variables cuantitativas:

```
ggplot(datos, aes(x = factor(Curricular.units.2nd.sem..evaluations.))) +
  geom_bar(fill = "#C26827", color = "#000000") +
  labs(
```

```
    title = "Distribución de Evaluaciones - 2do Semestre",
    x = "Cantidad de Evaluaciones",
    y = "Frecuencia"
  ) +
  theme_minimal()
```

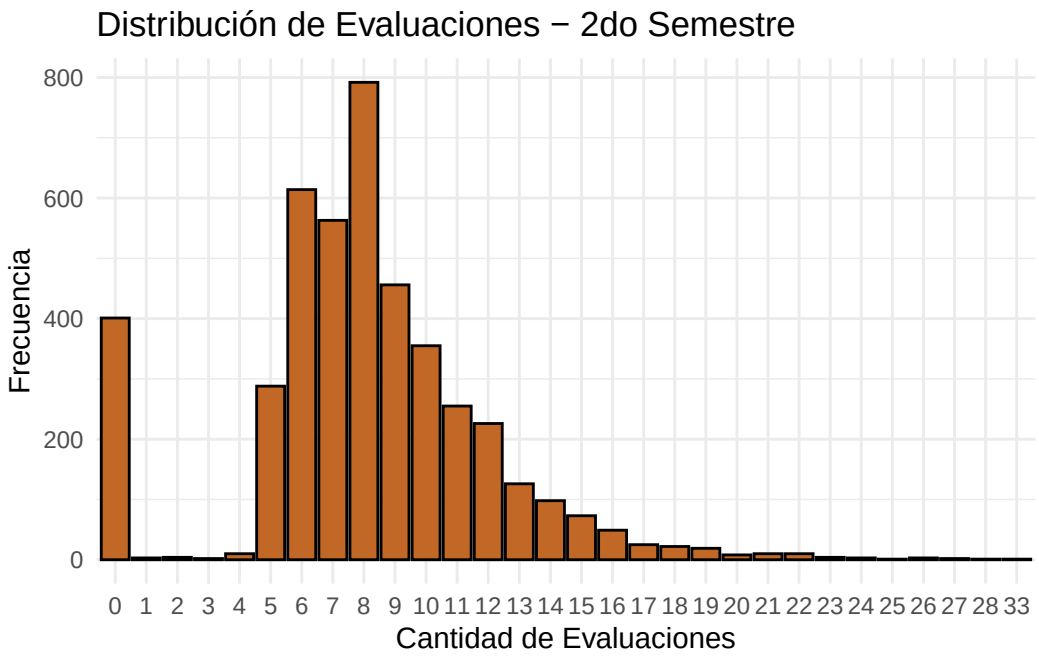

Hacer al menos dos gráficos que describan la relación entre las variables:

```
grafico_internacional_genero <- function(datos, genero, internacional, pais) {
  df_plot <- datos %>%
    mutate(
      genero = factor({{genero}}, levels = c(1, 0), labels = c("Hombres", "Mujeres")),
      tipo = factor({{internacional}}, levels = c(0, 1), labels = c("Nacional", "Interna
    ) %>%
    group_by(genero, tipo) %>%
```

```r
    summarise(Frecuencia = n(), .groups = "drop")

  ggplot(df_plot, aes(x = tipo, y = Frecuencia, fill = genero)) +
    geom_col(position = "dodge", width = 0.7) +
    geom_text(aes(label = Frecuencia),
              position = position_dodge(width = 0.7),
              vjust = -0.3, size = 3.5) +
    scale_fill_manual(values = c("#BA6F14", "#FF0000")) +
    labs(
      title = "Distribución de Internacionales y Nacionales por Género",
      x = "Lugar de Procedencia",
      y = "Frecuencia",
      fill = "Género"
    ) +
    theme_minimal(base_size = 12) +
    theme(
      legend.position = "bottom",
      plot.title = element_text(face = "bold"),
      axis.text.x = element_text(angle = 0, hjust = 0.5)
    )
}
grafico_internacional_genero(datos, datos$Gender, datos$International, datos$Nacionality
```

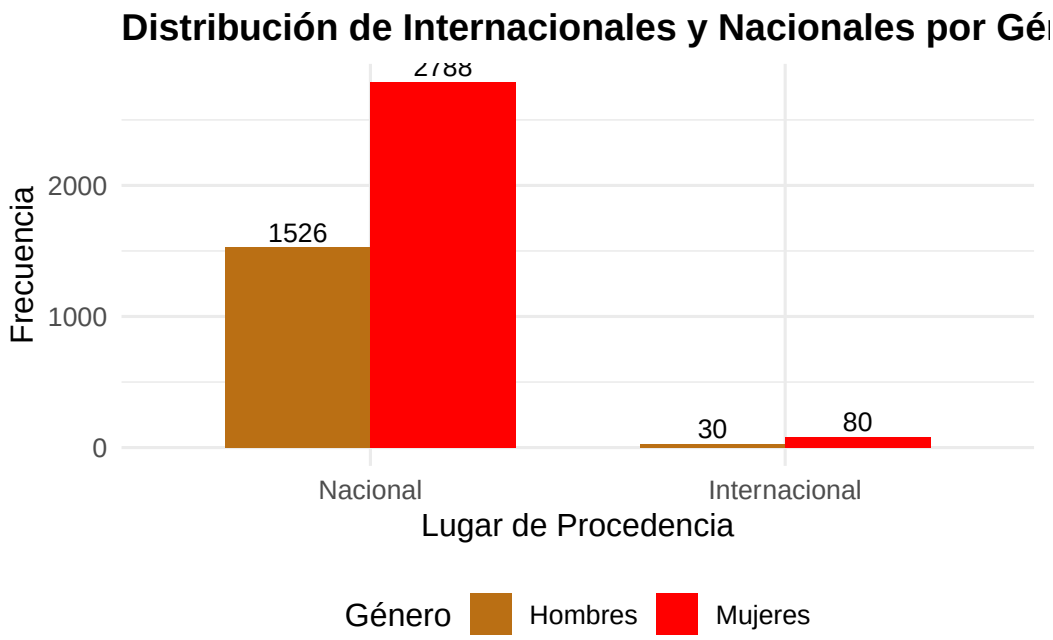


```
gráfico_necesidad_genero <- function(df, genero, needs){
  df_plot <- datos %>%
    mutate(
      genero = factor({{genero}}, levels = c(1, 0), labels = c("Hombres", "Mujeres")),
      necesidades = factor({{needs}}, levels = c(0, 1),
      labels = c("Sin necesidades especiales", "Con necesidades especiales"))
    ) %>%
    group_by(genero, necesidades) %>%
    summarise(Frecuencia = n(), .groups = "drop")

  ggplot(df_plot, aes(x = necesidades, y = Frecuencia, fill = genero)) +
    geom_col(position = "dodge", width = 0.7) +
    geom_text(aes(label = Frecuencia),
    position = position_dodge(width = 0.7),
    vjust = -0.3, size = 3.5) +
    scale_fill_manual(values = c("#1250C4", "#8F0FD6")) +
    labs(
```

```
      title = "Distribución de Necesidades Educativas Especiales por Género",
      x = "Condición",
      y = "Frecuencia",
      fill = "Género"
    ) +
    theme_minimal(base_size = 12) +
    theme(
      legend.position = "bottom",
      plot.title = element_text(face = "bold"),
      axis.text.x = element_text(angle = 0, hjust = 0.5)
    )
}
gráfico_necesidad_genero(datos, datos$Gender, datos$Educational.special.needs)
```

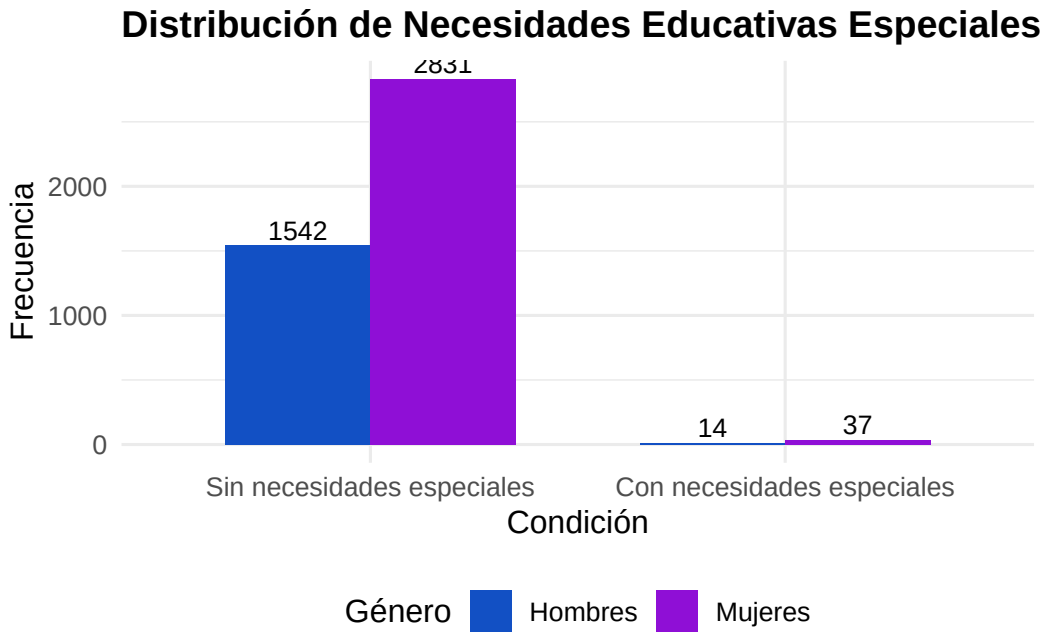

Hacer al menos un gráfico que muestre la distribución de las variables categóricas:

```
ggplot(datos, aes(x = factor(Gender,
                             levels = c(0, 1),
                             labels = c("Mujer", "Hombre")))) +
  geom_bar(fill = "#6049A6", color = "#42298A") +
  labs(
    title = "Distribución por Género",
    x = "Género",
    y = "Frecuencia"
  ) +
  theme_minimal()
```

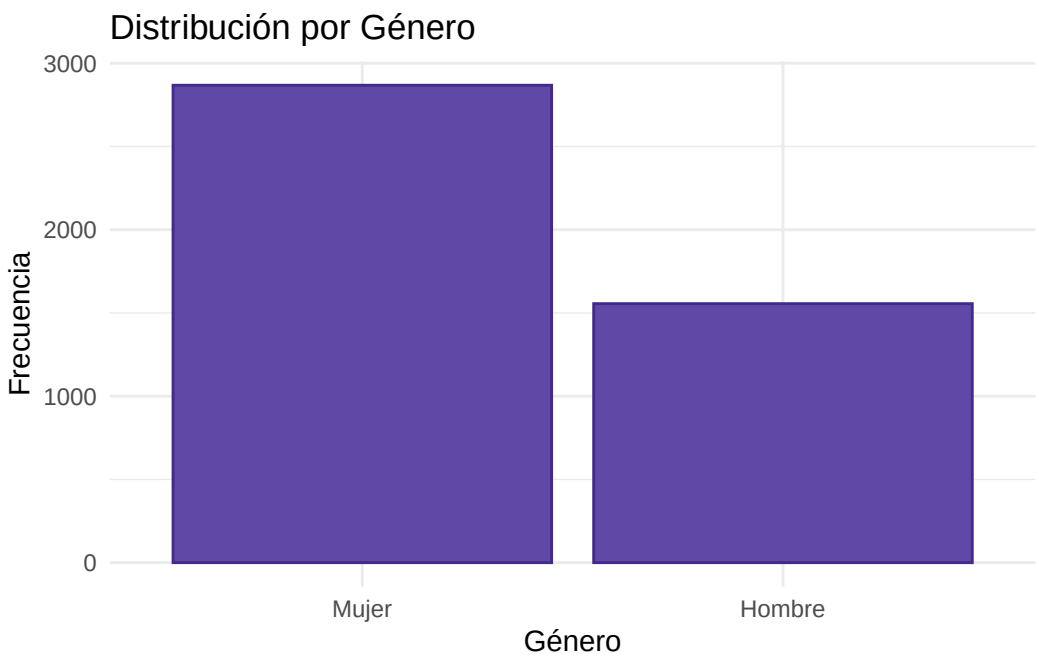

Identificar valores faltantes y posibles outliers:

```
datos_faltantes <- datos %>%
  filter(if_any(everything(),is.na))
head(datos_faltantes)
```

```
 [1] Marital.status
 [2] Application.mode
 [3] Application.order
 [4] Course
 [5] Daytime.evening.attendance.
 [6] Previous.qualification
 [7] Previous.qualification..grade.
 [8] Nacionality
 [9] Mother.s.qualification
[10] Father.s.qualification
[11] Mother.s.occupation
[12] Father.s.occupation
[13] Admission.grade
[14] Displaced
[15] Educational.special.needs
[16] Debtor
[17] Tuition.fees.up.to.date
[18] Gender
[19] Scholarship.holder
[20] Age.at.enrollment
[21] International
[22] Curricular.units.1st.sem..credited.
[23] Curricular.units.1st.sem..enrolled.
[24] Curricular.units.1st.sem..evaluations.
```

```
[25] Curricular.units.1st.sem..approved.
[26] Curricular.units.1st.sem..grade.
[27] Curricular.units.1st.sem..without.evaluations.
[28] Curricular.units.2nd.sem..credited.
[29] Curricular.units.2nd.sem..enrolled.
[30] Curricular.units.2nd.sem..evaluations.
[31] Curricular.units.2nd.sem..approved.
[32] Curricular.units.2nd.sem..grade.
[33] Curricular.units.2nd.sem..without.evaluations.
[34] Unemployment.rate
[35] Inflation.rate
[36] Target
<0 rows> (o 0- extensión row.names)
```

```r
datos %>%
  summarise(
    across(
      where(is.numeric),
      ~sum(
        .<quantile(.,0.25,na.rm=TRUE)-1.5*IQR(.)|
        .>quantile(.,0.75,na.rm=TRUE)+1.5*IQR(.),na.rm = TRUE

      )
    )
  )#cantidad de outliners por variable
```

```
  Marital.status Application.mode Application.order Course
1            505                0               541    442
  Daytime.evening.attendance. Previous.qualification Nacionality
1                         483                    707         110
```

```
  Mother.s.qualification Father.s.qualification Mother.s.occupation
1                      0                      0                182
  Father.s.occupation Displaced Educational.special.needs Debtor
1                 177         0                        51    503
  Tuition.fees.up.to.date Gender Scholarship.holder Age.at.enrollment
1                     528      0               1099               441
  International Curricular.units.1st.sem..credited.
1           110                                  577
  Curricular.units.1st.sem..enrolled. Curricular.units.1st.sem..evaluations.
1                                 424                                     158
  Curricular.units.1st.sem..approved.
1                                 180
  Curricular.units.1st.sem..without.evaluations.
1                                         294
  Curricular.units.2nd.sem..credited. Curricular.units.2nd.sem..enrolled.
1                                 530                                  369
  Curricular.units.2nd.sem..evaluations. Curricular.units.2nd.sem..approved.
1                                   109                                   44
  Curricular.units.2nd.sem..without.evaluations.
1                                         282
```

```r
es_outlier <- function(x) {

  if(!is.numeric(x)) return(rep(FALSE,length(x)))
  q1 <- quantile(x,0.25,na.rm = TRUE)
  q3 <- quantile(x,0.75,na.rm = TRUE)

  resultado <- x<(q1-1.5*IQR(x,na.rm = TRUE))|
               x>(q3+1.5*IQR(x,na.rm = TRUE))
  return(resultado)
```

```
}


outliers <- as.data.frame(sapply(datos,es_outlier))
head(outliers)
```

```
  Marital.status Application.mode Application.order Course
1          FALSE            FALSE              TRUE   TRUE
2          FALSE            FALSE             FALSE  FALSE
3          FALSE            FALSE              TRUE  FALSE
4          FALSE            FALSE             FALSE  FALSE
5           TRUE            FALSE             FALSE   TRUE
6           TRUE            FALSE             FALSE  FALSE
  Daytime.evening.attendance. Previous.qualification
1                       FALSE                  FALSE
2                       FALSE                  FALSE
3                       FALSE                  FALSE
4                       FALSE                  FALSE
5                        TRUE                  FALSE
6                        TRUE                   TRUE
  Previous.qualification..grade. Nacionality Mother.s.qualification
1                          FALSE       FALSE                  FALSE
2                          FALSE       FALSE                  FALSE
3                          FALSE       FALSE                  FALSE
4                          FALSE       FALSE                  FALSE
5                          FALSE       FALSE                  FALSE
6                          FALSE       FALSE                  FALSE
  Father.s.qualification Mother.s.occupation Father.s.occupation
1                  FALSE               FALSE               FALSE
2                  FALSE               FALSE               FALSE
3                  FALSE               FALSE               FALSE
```

```
4                  FALSE               FALSE               FALSE
5                  FALSE               FALSE               FALSE
6                  FALSE               FALSE               FALSE
  Admission.grade Displaced Educational.special.needs Debtor
1           FALSE     FALSE                     FALSE  FALSE
2           FALSE     FALSE                     FALSE  FALSE
3           FALSE     FALSE                     FALSE  FALSE
4           FALSE     FALSE                     FALSE  FALSE
5           FALSE     FALSE                     FALSE  FALSE
6           FALSE     FALSE                     FALSE   TRUE
  Tuition.fees.up.to.date Gender Scholarship.holder Age.at.enrollment
1                   FALSE  FALSE              FALSE             FALSE
2                    TRUE  FALSE              FALSE             FALSE
3                    TRUE  FALSE              FALSE             FALSE
4                   FALSE  FALSE              FALSE             FALSE
5                   FALSE  FALSE              FALSE              TRUE
6                   FALSE  FALSE              FALSE              TRUE
  International Curricular.units.1st.sem..credited.
1         FALSE                               FALSE
2         FALSE                               FALSE
3         FALSE                               FALSE
4         FALSE                               FALSE
5         FALSE                               FALSE
6         FALSE                               FALSE
  Curricular.units.1st.sem..enrolled. Curricular.units.1st.sem..evaluations.
1                                TRUE                                  FALSE
2                               FALSE                                  FALSE
3                               FALSE                                  FALSE
4                               FALSE                                  FALSE
5                               FALSE                                  FALSE
```

```
6                                FALSE                                FALSE
  Curricular.units.1st.sem..approved. Curricular.units.1st.sem..grade.
1                                FALSE                                FALSE
2                                FALSE                                FALSE
3                                FALSE                                FALSE
4                                FALSE                                FALSE
5                                FALSE                                FALSE
6                                FALSE                                FALSE
  Curricular.units.1st.sem..without.evaluations.
1                                      FALSE
2                                      FALSE
3                                      FALSE
4                                      FALSE
5                                      FALSE
6                                      FALSE
  Curricular.units.2nd.sem..credited. Curricular.units.2nd.sem..enrolled.
1                                FALSE                                 TRUE
2                                FALSE                                FALSE
3                                FALSE                                FALSE
4                                FALSE                                FALSE
5                                FALSE                                FALSE
6                                FALSE                                FALSE
  Curricular.units.2nd.sem..evaluations. Curricular.units.2nd.sem..approved.
1                                 FALSE                                FALSE
2                                 FALSE                                FALSE
3                                 FALSE                                FALSE
4                                 FALSE                                FALSE
5                                 FALSE                                FALSE
6                                  TRUE                                FALSE
  Curricular.units.2nd.sem..grade.
```

```
1                              FALSE
2                              FALSE
3                              FALSE
4                              FALSE
5                              FALSE
6                              FALSE
  Curricular.units.2nd.sem..without.evaluations. Unemployment.rate
1                                          FALSE             FALSE
2                                          FALSE             FALSE
3                                          FALSE             FALSE
4                                          FALSE             FALSE
5                                          FALSE             FALSE
6                                           TRUE             FALSE
  Inflation.rate Target
1          FALSE  FALSE
2          FALSE  FALSE
3          FALSE  FALSE
4          FALSE  FALSE
5          FALSE  FALSE
6          FALSE  FALSE
```

Investigar técnicas que permitan subsanar los valores perdidos y outliers

Manejo de valores faltantes y outliers

Valores faltantes:

Los valores faltantes pueden ser tratados mediante diferentes métodos que modifican los datos de distinta manera. Por eso, a la hora de utilizarlos, sus resultados se verán afectados de mayor o menor forma dependiendo de la técnica utilizada. Existen técnicas como la eliminación de los

datos faltantes, sin embargo, esta práctica puede perjudicar el análisis de los datos, por lo que nos centraremos en los métodos que buscan modificarlos de manera que aporten información.

Se pueden utilizar métodos simples como la imputación por la media, mediana o moda, que son fáciles de implementar; sin embargo, estos datos pueden verse distorsionados por la presencia de valores atípicos. Por eso existen métodos más robustos como la imputación por vecinos más cercanos, imputación por regresión, imputación múltiple o imputación por series de tiempo. Estas técnicas conservan de mejor manera la estructura de los datos.

Outliers:

Hay tres opciones posibles a la hora de enfrentar un outlier, tanto univariable como multivariable. Estas opciones son eliminarlo, mantenerlo o reemplazarlo. Al igual que con los valores faltantes, se pueden eliminar todos los outliers, pero este método provoca pérdida de información que normalmente es valiosa y aporta a la investigación.

También se tiene la opción de utilizar métodos simples como reemplazarlos por la media o la moda, aunque el uso de estas técnicas no es recomendado porque puede generar resultados artificiales y sesgados. Por lo tanto, se recomienda utilizar técnicas más robustas que reduzcan su influencia sin eliminarlos por completo.

Ahora veremos algunas formas de enfrentar los outliers dependiendo de si son univariables o multivariables.

Outliers univariable

Detectar y clasificar: Se realiza una revisión manual para determinar si son errores, casos aleatorios o datos de interés que deberían analizarse por separado. Luego se decide individualmente qué hacer con cada uno.

Winsorización: Se sustituye el dato por el valor del percentil más cercano. Esto conserva la estructura de los datos y limita los efectos sobre las estadísticas principales.

Outliers multivariable

Revisión contextual: Se verifica que las variables que se estén comparando no tengan una relación incoherente o anómala que genere valores extraños o fuera de contexto.

Análisis por separado: Se analizan los casos atípicos como un conjunto separado de los datos comunes para identificar patrones sin alterar los datos principales.

Regresión: Son métodos que consisten en modelar la relación de una variable dependiente con otras independientes, para evaluar la influencia de los outliers sobre las relaciones entre variables.

Bibliografía:

Rosas, J. F. M. (2009). *Métodos de imputación para el tratamiento de datos faltantes*. Revista de Métodos Cuantitativos para la Economía y la Empresa. Recuperado de https://www.redalyc.org/pdf/2331/2331172

Medina, F., & Galván, M. (2007). *Imputación de datos: Teoría y práctica*. Serie Estudios Estadísticos y Prospectivos, N.º 54. Santiago de Chile: ONU-CEPAL. https://repositorio.cepal.org/server/api/core/bitstreams/02dd479f-fae2-43c4-b5ec-5419fa7f6190/content

Rosas, J. F. M., & Álvarez Verdejo, E. (2009). *Métodos de imputación para el tratamiento de datos faltantes: Aplicación mediante R/S-PLUS*. Revista de Métodos Cuantitativos para la Economía y la Empresa, (07), 03-30. https://www.redalyc.org/pdf/2331/233117228001.pdf

Cousineau, D. (2010). *Outliers detection and treatment: A review*. International Journal of Psychological Research, 3(1), 58-67. https://www.redalyc.org/pdf/2990/299023509004.pdf

Leys, C., Delacre, M., Mora, Y. L., Lakens, D., & Ley, C. (2019). How to classify, detect, and manage univariate and multivariate outliers, with emphasis on pre-registration. *International Review of Social Psychology, 32*(1). https://doi.org/10.5334/irsp.289

==========

Bitácora 3 ==========

1. Técnicas o Métodos Estadísticos Seleccionados

Estadística descriptiva: Nos ayuda a recolectar, organizar, analizar y presentar un junto de datos que nos ayudan a saber sus principales características

Regresión Logística Binaria: para modelar la probabilidad de deserciónen función de factores individuales, sociales y académicos.

2.Marco Metodológico

Etapas preliminares del analisis

Estadística descriptiva: Nos ayuda a recolectar, organizar, analizar y presentar un conjunto de datos que nos ayuda a conocer sus principales características.

Análisis Exploratorio de Datos (EDA): Para comprender la distribución y relaciones básicas entre variables.

Método estadístico principal: Regresión Logística Binaria La regresión logística modela la probabilidad de que un evento ocurra (en este caso, deserción) mediante la función logística:

P(Y=1/X)=1/(1+e^−(β_0+β_1*X_1*+□+*β_p*X_p)) Donde:

Y es la variable dependiente binaria (Dropout vs Graduate/Enrolled) X_1,…,X_p son las variables predictoras β_0,…,β_p son los coeficientes a estimar La estimación se realiza mediante máxima verosimilitud, maximizando la función:

ℓ(β)=∑(i=1 hasta n)[y_i*log(p_i)+(1−y_i)*log(1−p_i)]

Fundamento estadístico: La regresión logística modela la relación entre un conjunto de variables predictoras y la probabilidad de ocurrencia del evento.

Justificación: En nuestro caso, la regresión logística binaria es apropiada ya que nuestro análisis está centrado en una variable binaria, que toma el valor 1 en caso de “Dropout” y 0 en caso contrario. El uso de esta técnica permite evaluar cómo se relacionan múltiples factores, que en nuestro caso pueden ser académicos y socioeconómicos. Nos facilita la interpretación mediante odds ratios, además de ser un método confiable y simple, ampliamente utilizado en investigación.

3- Aplique dichas técnicas o métodos. Presente los resultados, analícelos y responda su pregunta de investigación.

Estadística descriptiva

```
columnas_seleccionadas <- datos[, c(
                                    "Admission.grade",
                                    "Age.at.enrollment",
                                    "Previous.qualification..grade.",
```

```
                                  "Curricular.units.1st.sem..grade.",
                                  "Curricular.units.2nd.sem..grade."
                                   )]
#pasa r chr a num y pasar int a num
columnas_seleccionadas <- as.data.frame(lapply(columnas_seleccionadas, function(x) {
  if(is.character(x)) {
    # Convertir a numérico (maneja decimales)
    return(as.numeric(as.character(x)))
  } else {
    return(x)
  }
}))
str(columnas_seleccionadas)
```

```
'data.frame':   4424 obs. of  5 variables:
 $ Admission.grade                : num  127 142 125 120 142 ...
 $ Age.at.enrollment              : int  20 19 19 20 45 50 18 22 21 18 ...
 $ Previous.qualification..grade.  : num  122 160 122 122 100 ...
 $ Curricular.units.1st.sem..grade.: num  0 14 0 13.4 12.3 ...
 $ Curricular.units.2nd.sem..grade.: num  0 13.7 0 12.4 13 ...
```

```
calcular_moda <- function(x){
  x <- x[!is.na(x)]
  if(length(x) == 0) return(NA)

  tabla <- table(x)
  moda <- as.numeric((names(tabla)[tabla == max(tabla)]))
  return(moda[1])
}
```

```r
estadisticas_descrip <- data.frame(
  Media = sapply(columnas_seleccionadas, mean, na.rm = TRUE),
  Mediana = sapply(columnas_seleccionadas, median, na.rm = TRUE),
  Moda = sapply(columnas_seleccionadas, calcular_moda),
  Desviacion_Estandar = sapply(columnas_seleccionadas, sd, na.rm = TRUE),
  Minimo = sapply(columnas_seleccionadas, min, na.rm = TRUE),
  Maximo = sapply(columnas_seleccionadas, max, na.rm = TRUE),
  Rango = sapply(columnas_seleccionadas, function(x) diff(range(x, na.rm = TRUE)))
)
print(estadisticas_descrip)
```

```
                                    Media   Mediana  Moda Desviacion_Estandar
Admission.grade                  126.97812 126.10000 130.0           14.482001
Age.at.enrollment                 23.26514  20.00000  18.0            7.587816
Previous.qualification..grade.   132.61331 133.10000 133.1           13.188332
Curricular.units.1st.sem..grade.  10.64082  12.28571   0.0            4.843663
Curricular.units.2nd.sem..grade.  10.23021  12.20000   0.0            5.210808
                                  Minimo    Maximo    Rango
Admission.grade                       95 190.00000 95.00000
Age.at.enrollment                     17  70.00000 53.00000
Previous.qualification..grade.        95 190.00000 95.00000
Curricular.units.1st.sem..grade.       0  18.87500 18.87500
Curricular.units.2nd.sem..grade.       0  18.57143 18.57143
```

```r
par(mfrow = c(2, 4))  # Parámetros gráficos

nombres_var <- names(columnas_seleccionadas) # Extrae los nombres y los asigna al vector

for(i in 1:ncol(columnas_seleccionadas)) { # Bucle para generar los histogramas, iterand
  hist(columnas_seleccionadas[[i]], #Estructura que va a tener el histograma
```

```
        main = nombres_var[i],
        cex.main = 0.9,
        xlab = "Valor",
        ylab = "Frecuencia",
        col = "lightblue",
        border = "black")
}
```

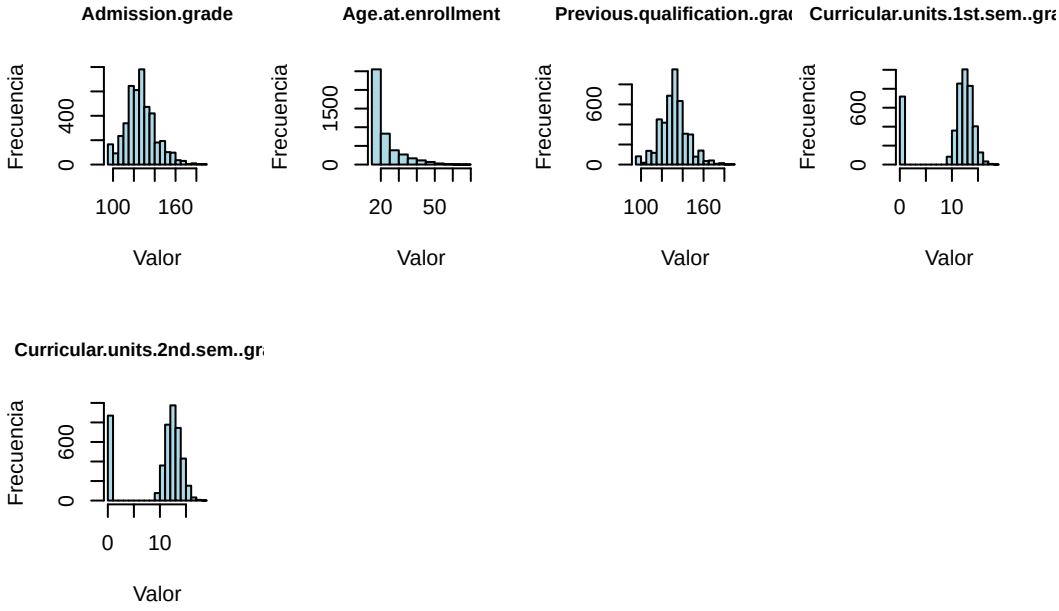

analisis En el análisis estadístico nos ayuda a poder ver las variables, pudiendo analizar y comprar, tipo se puede ver uno como la moda, lo cual sería los valores más frecuentes, el rango difiere entre valores máximos y mínimos. En las gráficas se puede ver los histogramas, en el cual se puede ver las variables que se seleccionaron y se le signaron en columnas_seleccionadas, se grafica esto, para tener una idea del comportamiento de estas variables.

Este apartado es para los tipos de variables

```
datos_num <- datos %>%
  select(
    Previous.qualification..grade.,
```

```
    Application.order,
    Admission.grade,
    Age.at.enrollment,
    Curricular.units.1st.sem..credited.,
    Curricular.units.1st.sem..enrolled.,
    Curricular.units.1st.sem..approved.,
    Curricular.units.1st.sem..evaluations.,
    Curricular.units.1st.sem..grade.,
    Curricular.units.1st.sem..without.evaluations.,
    Curricular.units.2nd.sem..credited.,
    Curricular.units.2nd.sem..enrolled.,
    Curricular.units.2nd.sem..evaluations.,
    Curricular.units.2nd.sem..approved.,
    Curricular.units.2nd.sem..grade.,
    Curricular.units.2nd.sem..without.evaluations.,
  )

tabla_num <- data.frame(
  Variables_Numericas = names(datos_num)
)

tabla_num
```

```
                              Variables_Numericas
1                  Previous.qualification..grade.
2                               Application.order
3                                 Admission.grade
4                               Age.at.enrollment
5             Curricular.units.1st.sem..credited.
6             Curricular.units.1st.sem..enrolled.
```

```
7             Curricular.units.1st.sem..approved.
8          Curricular.units.1st.sem..evaluations.
9                Curricular.units.1st.sem..grade.
10 Curricular.units.1st.sem..without.evaluations.
11            Curricular.units.2nd.sem..credited.
12            Curricular.units.2nd.sem..enrolled.
13         Curricular.units.2nd.sem..evaluations.
14            Curricular.units.2nd.sem..approved.
15               Curricular.units.2nd.sem..grade.
16 Curricular.units.2nd.sem..without.evaluations.
```

```r
datos_cat <- datos %>%
  select(
    Marital.status,
    Application.mode,
    Course,
    Daytime.evening.attendance.,
    Previous.qualification,
    Nacionality,
    Mother.s.qualification,
    Father.s.qualification,
    Mother.s.occupation,
    Father.s.occupation,
    Displaced,
    Educational.special.needs,
    Debtor,
    Tuition.fees.up.to.date,
    Gender,
    Scholarship.holder,
    International,
```

```
    Target
  )

tabla_cat <- data.frame(
  Variables_Categoricas = names(datos_cat)
)

tabla_cat
```

```
         Variables_Categoricas
1                Marital.status
2             Application.mode
3                      Course
4  Daytime.evening.attendance.
5       Previous.qualification
6                   Nacionality
7       Mother.s.qualification
8       Father.s.qualification
9          Mother.s.occupation
10         Father.s.occupation
11                   Displaced
12   Educational.special.needs
13                     Debtor
14     Tuition.fees.up.to.date
15                     Gender
16          Scholarship.holder
17               International
18                     Target
```

Aplicando Regresión Logística

Nota: Se utilizaron más técnicas para verificar la veracidad de la información obtenida, de esta manera, se presentan los resultados

```
#install.packages("rcompanion")
#install.packages("ResourceSelection")
#install.packages("pROC")
#install.packages("car")

library(rcompanion)
library(ResourceSelection)
library(pROC)
library(car)
### Pasamos los casos de Desertor y Matriculado/Graduado a 1,0 respectivamente
datos$Target_bin <- ifelse(datos$Target == "Dropout", 1, 0)
datos$Target_bin <- factor(datos$Target_bin, levels = c(0, 1))

modelo <- glm(Target_bin ~ Age.at.enrollment +
                Curricular.units.1st.sem..enrolled. +
                Curricular.units.1st.sem..approved. +
                Curricular.units.2nd.sem..enrolled. +
                Curricular.units.2nd.sem..approved. +
                Marital.status +
                Course +
                Displaced +
                Educational.special.needs +
                Debtor +
                Tuition.fees.up.to.date +
                Gender +
```

```
                Scholarship.holder +
                International +
                Mother.s.qualification +
                Father.s.qualification +
                Mother.s.occupation +
                Father.s.occupation,
              data = datos,
              family = binomial)

summary(modelo)
```

```
Call:
glm(formula = Target_bin ~ Age.at.enrollment + Curricular.units.1st.sem..enrolled. +
    Curricular.units.1st.sem..approved. + Curricular.units.2nd.sem..enrolled. +
    Curricular.units.2nd.sem..approved. + Marital.status + Course +
    Displaced + Educational.special.needs + Debtor + Tuition.fees.up.to.date +
    Gender + Scholarship.holder + International + Mother.s.qualification +
    Father.s.qualification + Mother.s.occupation + Father.s.occupation,
    family = binomial, data = datos)

Coefficients:
                                  Estimate Std. Error z value Pr(>|z|)
(Intercept)                      3.281e-01  3.061e-01   1.072  0.28376
Age.at.enrollment                5.174e-02  8.160e-03   6.340 2.30e-10 ***
Curricular.units.1st.sem..enrolled.  1.938e-01  7.154e-02   2.709  0.00675 **
Curricular.units.1st.sem..approved. -2.236e-01  3.999e-02  -5.591 2.26e-08 ***
Curricular.units.2nd.sem..enrolled.  4.547e-01  7.994e-02   5.688 1.28e-08 ***
Curricular.units.2nd.sem..approved. -6.501e-01  3.752e-02 -17.325  < 2e-16 ***
Marital.status                   -1.547e-01  9.662e-02  -1.601  0.10930
```

```
Course                                -7.115e-05  2.369e-05  -3.004  0.00267 **
Displaced                              2.428e-01  1.066e-01   2.276  0.02283 *
Educational.special.needs              3.750e-01  4.074e-01   0.920  0.35738
Debtor                                 4.756e-01  1.602e-01   2.969  0.00299 **
Tuition.fees.up.to.date               -2.300e+00  1.744e-01 -13.189  < 2e-16 ***
Gender                                 3.119e-01  1.017e-01   3.068  0.00215 **
Scholarship.holder                    -5.670e-01  1.351e-01  -4.197 2.70e-05 ***
International                         -6.478e-01  3.343e-01  -1.938  0.05264 .
Mother.s.qualification                 8.506e-03  3.856e-03   2.206  0.02739 *
Father.s.qualification                -3.450e-03  3.808e-03  -0.906  0.36498
Mother.s.occupation                   -1.205e-02  4.667e-03  -2.582  0.00981 **
Father.s.occupation                    2.169e-03  4.781e-03   0.454  0.65006
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 5554.5  on 4423  degrees of freedom
Residual deviance: 2857.5  on 4405  degrees of freedom
AIC: 2895.5

Number of Fisher Scoring iterations: 5
```

```r
### Convertir coeficientes a Odds Ratios

exp(coef(modelo))
```

```
                        (Intercept)                      Age.at.enrollment
                          1.3883642                              1.0530970
Curricular.units.1st.sem..enrolled.  Curricular.units.1st.sem..approved.
```

```
                          1.2138236                           0.7996545
Curricular.units.2nd.sem..enrolled. Curricular.units.2nd.sem..approved.
                          1.5756897                           0.5220126
                     Marital.status                              Course
                          0.8566540                           0.9999289
                          Displaced           Educational.special.needs
                          1.2747588                           1.4549726
                             Debtor             Tuition.fees.up.to.date
                          1.6089201                           0.1002784
                             Gender                  Scholarship.holder
                          1.3660759                           0.5672287
                      International              Mother.s.qualification
                          0.5231712                           1.0085426
             Father.s.qualification                 Mother.s.occupation
                          0.9965560                           0.9880200
                Father.s.occupation
                          1.0021713
```

```r
## intervalos de confianza
exp(confint(modelo))
```

```
                                        2.5 %    97.5 %
(Intercept)                        0.76298132 2.5346840
Age.at.enrollment                  1.03637701 1.0700896
Curricular.units.1st.sem..enrolled. 1.05323464 1.3945712
Curricular.units.1st.sem..approved. 0.73939508 0.8649507
Curricular.units.2nd.sem..enrolled. 1.34938965 1.8466195
Curricular.units.2nd.sem..approved. 0.48453253 0.5613541
Marital.status                     0.70771288 1.0335316
Course                             0.99988262 0.9999756
```

```
Displaced                          1.03520944 1.5727865
Educational.special.needs          0.63708361 3.1658270
Debtor                             1.17358287 2.1998528
Tuition.fees.up.to.date            0.07083641 0.1404101
Gender                             1.11880938 1.6668522
Scholarship.holder                 0.43381057 0.7369488
International                      0.26680737 0.9898260
Mother.s.qualification             1.00095438 1.0162059
Father.s.qualification             0.98914065 1.0040234
Mother.s.occupation                0.97888650 0.9970416
Father.s.occupation                0.99279309 1.0116109
```

```
### Evaluación del modelo


# Nagelkerke
nagelkerke(modelo)
```

```
$Models

Model: "glm, Target_bin ~ Age.at.enrollment + Curricular.units.1st.sem..enrolled. + Curr
Null:  "glm, Target_bin ~ 1, binomial, datos"

$Pseudo.R.squared.for.model.vs.null
                            Pseudo.R.squared
McFadden                           0.485563
Cox and Snell (ML)                 0.456457
Nagelkerke (Cragg and Uhler)       0.638330

$Likelihood.ratio.test
 Df.diff LogLik.diff  Chisq p.value
```

```
     -18     -1348.5 2697.1       0

$Number.of.observations

Model: 4424
Null:  4424

$Messages
[1] "Note: For models fit with REML, these statistics are based on refitting with ML"

$Warnings
[1] "None"
```

```r
# Matriz de confusión
prob <- predict(modelo, type = "response")
pred <- ifelse(prob > 0.5, 1, 0)
pred <- factor(pred, levels = c(0, 1))

table(Predicción = pred, Real = datos$Target_bin)
```

```
          Real
Predicción    0    1
         0 2836  379
         1  167 1042
```

```r
# Curva ROC y AUC

roc_curve <- roc(datos$Target_bin, prob)
auc(roc_curve)
```

```
Area under the curve: 0.9154
```

```
### Revisar multicolinealidad (VIF)
vif(modelo)
```

```
                 Age.at.enrollment Curricular.units.1st.sem..enrolled.
                          1.753128                             14.649118
Curricular.units.1st.sem..approved. Curricular.units.2nd.sem..enrolled.
                          5.268771                             14.998800
Curricular.units.2nd.sem..approved.                       Marital.status
                          4.075880                              1.456451
                            Course                             Displaced
                          1.727072                              1.205242
          Educational.special.needs                                Debtor
                          1.006361                              1.142268
           Tuition.fees.up.to.date                                Gender
                          1.151121                              1.078595
                Scholarship.holder                         International
                          1.061526                              1.034956
            Mother.s.qualification               Father.s.qualification
                          1.567911                              1.487045
              Mother.s.occupation                  Father.s.occupation
                          5.002125                              4.939781
```

Calidad global del modelo

Nagelkerke= 0.638

Un pseudo-R^2 de 0.63 es excelente para un modelo de regresión logística, ya que logra explicar un 63% de la probabilidad de deserción.

***AUC* = 0.915**

Esto quiere decir que es un modelo altamente predictivo, ya que según su escala, por encima del 0.90 es un modelo sobresaliente

Interpretación de coeficientes importantes (Odds Ratios)

Variables académicas

Son las más relevantes. Dominan completamente el modelo.

Variable	OR	Interpretación
1st.sem.enrolled	**1.21**	Cada curso *inscrito* extra implica que aumente la probabilidad de deserción 21%
1st.sem.approved	**0.80**	Cada curso aprobado extra implica que reduce un 20% la probabilidad
2nd.sem.enrolled	**1.57**	Los estudiantes "sobrecargados" tienden a salirse
2nd.sem.approved	**0.52**	Cada aprobación implica que reduzca la probabilidad en casi 50%

Conclusión: La carga académica y el rendimiento explican casi toda la deserción.

Variables financieras

Variable	OR	Interpretación
Tuition.fees.up.to.date	**0.10**	Estar al día reduce la deserción un 90%

Variable	OR	Interpretación
Debtor	**1.61**	Los deudores hacen que aumente un 61% la probabilidad

Conclusión: Las finanzas son otro bloque crítico.

Variables personales

Variable	OR	Interpretación
Age.at.enrollment	**1.05**	Más edad → ↑ riesgo pequeño pero significativo
Gender (Hombres)	**1.37**	Mayor riesgo que las mujeres
Scholarship.holder	**0.56**	Becarios desertan menos

Variables familiares

Estás variables aportan, pero marginalmente.

Variable	p-valor	OR	Conclusión
Mother.s.qualification	0.027	1.008	Efecto pequeño, pero significativo
Mother.s.occupation	0.009	0.988	Ligera reducción del riesgo

Variables que no aportan

- Toda variable relacionada con el padre
- La nacionalidad

Matriz de confusión

El código presenta lo siguiente:

- Verdaderos negativos: 2836
- Falsos negativos: 379
- Verdaderos positivos: 1042
- Falsos positivos: 167

Métricas aproximadas:

- Efectividad ≈ 88.0%
- Sensibilidad ≈ 73%
- Especificidad ≈ 94%

Así, el modelo detecta muy bien a los que NO desertan; sin embargo, se pierde un porcentaje considerable de desertores (379 casos).

Conclusiones claras

Así entonces, podemos concluir, gracias a la técnica de Regresión Logística, que los factores que afectan más a las deserciones en educación superior son los factores financieros y académicos. Además, se presentan los factores personales y familiares, los cuales generan un aporte en la deserción, pero no de manera tan significativa. De igual manera, existen factores geográficos y personales que no afectan en lo absoluto en la deserción.

Gráficos relacionados:

```
datos %>%
  mutate(
    Target = factor(
      Target,
      levels = c("Graduate", "Enrolled", "Dropout"),
      labels = c("No Desertor", "No Desertor", "Desertor")
    )
  ) %>%
  ggplot(aes(x = Target, fill = Target)) +
  geom_bar(aes(y = after_stat(count / sum(count)))) +
  geom_text(
    aes(
      y = after_stat(count / sum(count)),
      label = paste0(round(after_stat(count / sum(count)) * 100, 1), "%")
    ),
    stat = "count",
    vjust = -0.5,
    size = 4
  ) +
```

```
  scale_fill_manual(
    values = c("No Desertor" = "steelblue",
               "Desertor"    = "firebrick")
  ) +
  labs(
    title = "Distribución de Deserción Escolar",
    x = "Estado del Estudiante",
    y = "Proporción"
  )
```

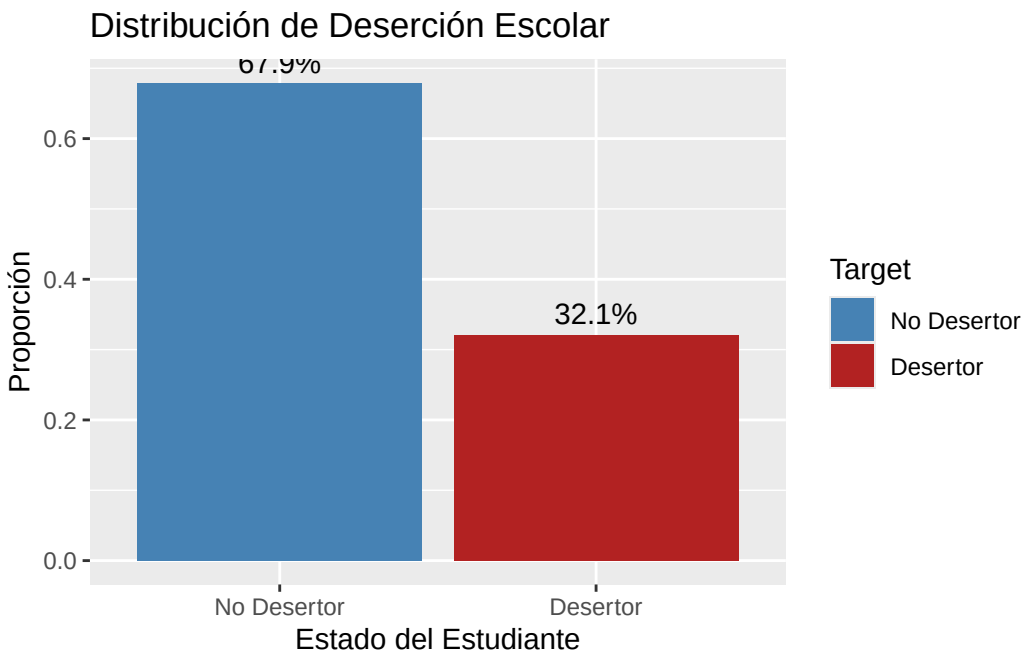


```
datos %>%
  mutate(
    Target = factor(Target,
                    levels = c("Graduate", "Enrolled", "Dropout"),
                    labels = c("No Desertor", "No Desertor", "Desertor"))
  ) %>%
  # Agrupar para proporciones
  group_by(Gender, Target) %>%
```

```r
summarise(n = n(), .groups = "drop") %>%
group_by(Gender) %>%
mutate(prop = n / sum(n)) %>%

ggplot(aes(x = factor(Gender), y = prop, fill = Target)) +
geom_bar(stat = "identity", position = "stack", alpha = 0.9) +
geom_text(
  aes(label = paste0(round(prop * 100, 1), "%")),
  position = position_stack(vjust = 0.5),
  color = "white",
  fontface = "bold",
  size = 4
) +

scale_fill_manual(values = c("steelblue", "firebrick")) +

scale_y_continuous(labels = scales::percent) +

labs(
  title = "Distribución de Deserción por Género",
  x = "Género (0 = Mujer, 1 = Hombre)",
  y = "Proporción",
  fill = "Estado"
)
```

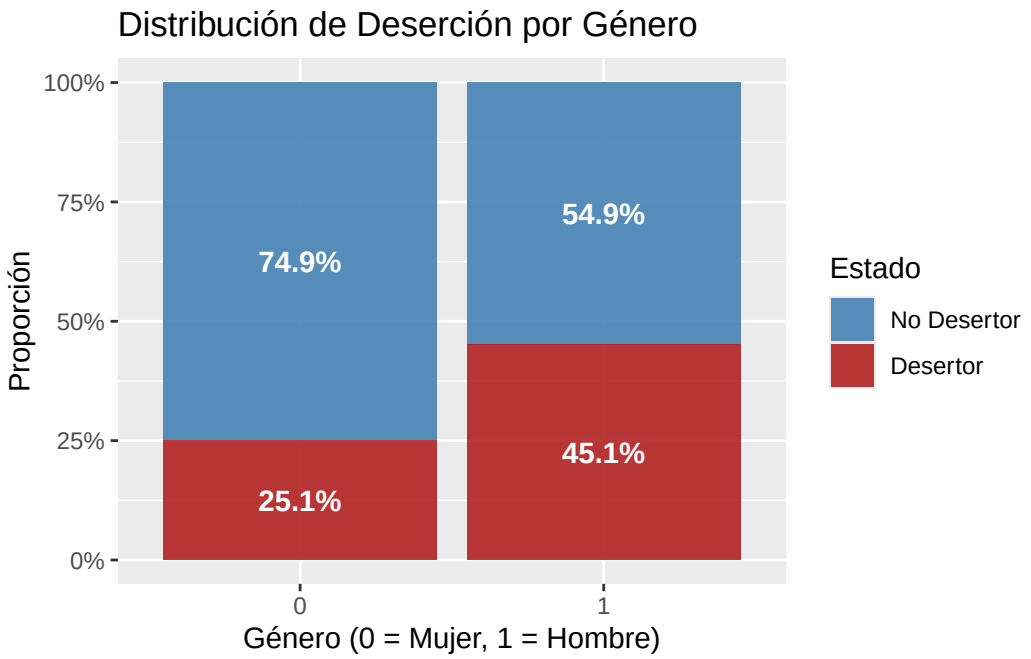


```
datos %>%
  mutate(
    Target = factor(
      Target,
      levels = c("Graduate", "Enrolled", "Dropout"),
      labels = c("No Desertor", "No Desertor", "Desertor")
    )
  ) %>%
  count(Age.at.enrollment, Target) %>%
  group_by(Age.at.enrollment) %>%
  mutate(prop = n / sum(n)) %>%

  ggplot(aes(x = Age.at.enrollment, y = prop, color = Target)) +
  geom_line(size = 1.3, alpha = 0.9) +
  geom_point(size = 3) +
  scale_color_manual(
    values = c("No Desertor" = "steelblue",
```

```
                "Desertor"    = "firebrick")
  ) +
  scale_y_continuous(labels = scales::percent_format()) +
  labs(
    title = "Proporción de Deserción según la Edad de Ingreso",
    x = "Edad al momento de ingreso",
    y = "Proporción",
    color = "Estado"
  )
```

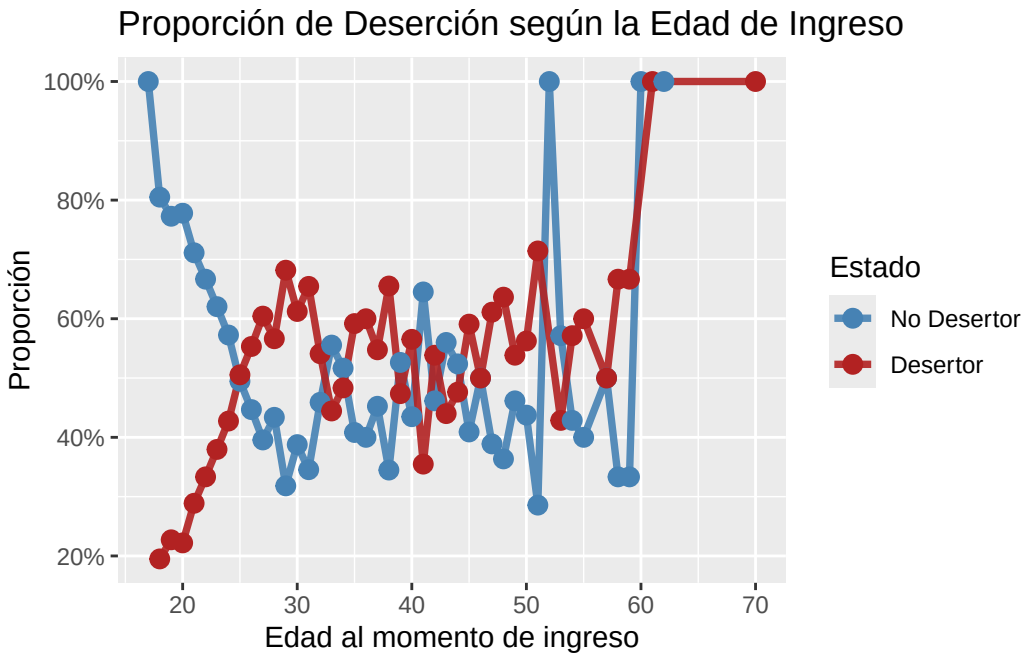


```
datos %>%
  mutate(
    Target = factor(
      Target,
      levels = c("Graduate", "Enrolled", "Dropout"),
      labels = c("No desertor", "No desertor", "Desertor")
    )
  ) %>%
```

```r
  select(
    Target,
    Matriculados = Curricular.units.1st.sem..enrolled.,
    Aprobados = Curricular.units.1st.sem..approved.
  ) %>%
  pivot_longer(
    cols = c(Matriculados, Aprobados),
    names_to = "Variable",
    values_to = "Valor"
  ) %>%

  ggplot(aes(x = Target, y = Valor, fill = Variable)) +
  geom_boxplot(alpha = 0.75, width = 0.7, outlier.size = 1.5) +

  scale_fill_manual(
    values = c("Matriculados" = "steelblue",
               "Aprobados" = "firebrick")
  ) +

  labs(
    title = "Distribución de Créditos Matriculados y Aprobados en el 1er Semestre según
    x = "Estado académico",
    y = "Número de créditos",
    fill = ""
  )
```

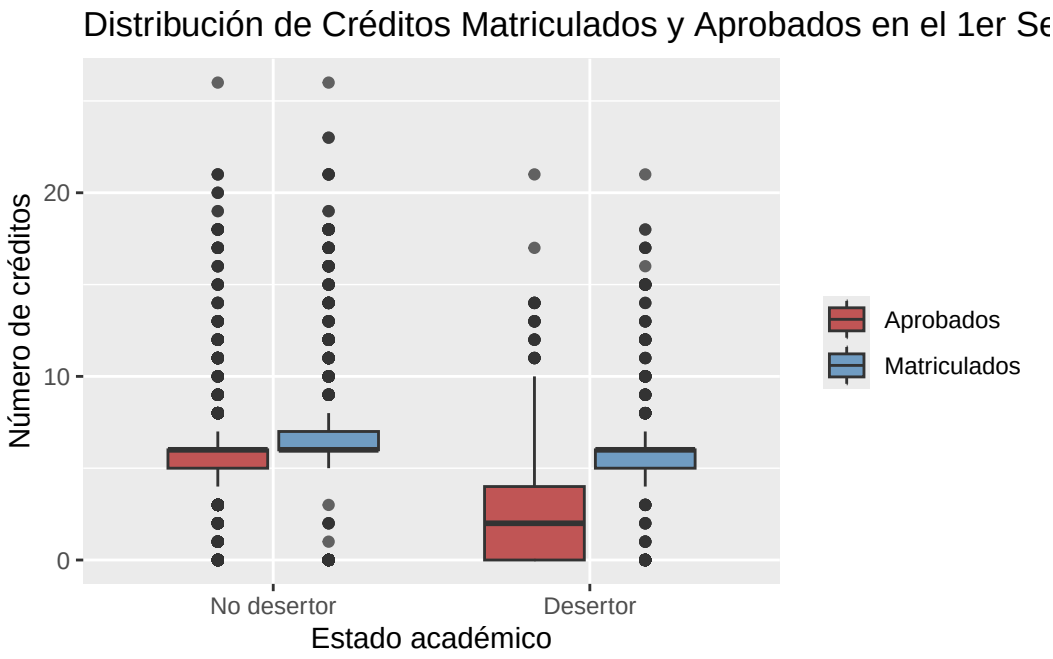


```r
datos %>%
  mutate(
    Target = factor(
      Target,
      levels = c("Graduate", "Enrolled", "Dropout"),
      labels = c("No desertor", "No desertor", "Desertor")
    )
  ) %>%
  select(
    Target,
    Matriculados = Curricular.units.2nd.sem..enrolled.,
    Aprobados = Curricular.units.2nd.sem..approved.
  ) %>%
  pivot_longer(
    cols = c(Matriculados, Aprobados),
    names_to = "Variable",
    values_to = "Valor"
```

```
) %>%

ggplot(aes(x = Target, y = Valor, fill = Variable)) +
geom_boxplot(alpha = 0.75, width = 0.7, outlier.size = 1.5) +

scale_fill_manual(
  values = c("Matriculados" = "steelblue",
             "Aprobados" = "firebrick")
) +

labs(
  title = "Distribución de Créditos Matriculados y Aprobados en el 2do Semestre según
  x = "Estado académico",
  y = "Número de créditos",
  fill = ""
)
```